

EvalPilot

AI 应用回归评测 与自主发布质量官

用匹配评测、统计置信和反事实重放，把版本变化变成可验收的发布决策。

8 / 26 回归 · 52 / 0 上游比较 · 4 / 4 00D 根因

产品站: zqian6263-design.github.io/EvalPilot

视频: bilibili.com/video/BV1mPYY6sE1k

EVALPILOT

AI 应用发布前的 回归证据决策

真实回归

不是只看总分变化，而是区分版本变更与噪声。

根因定位

通过反事实重放找出导致失败的变更。

可验收结论

交付可审计的发布裁决、证据与报告。

普通问答通过，不等于关键能力没有退化

版本更新可能更快、总分更高，却同时破坏产品必须长期守住的能力。

条款与流程丢失

退款、升级、电池处置等强制条款被摘要压缩掉。

权限与隔离失效



租户记忆串扰、缓存返回旧错误，业务边界被绕过。

安全护栏失效

凭证注入从拒绝泄露变成直接输出敏感信息。

需要的是：是否真实回归、由哪个变更造成、是否应立即阻断发布。


一个能接管发布质量闭环的数字员工



交付物不是建议

- Markdown 证据报告
- CI 退出码 0 / 1 / 2
- run id 与 evidence id

模型可以规划，但不能覆盖实测结论



LLM 权限

- ☐ 提出风险假设
- ☐ 选择可执行实验
- ☐ 解释证据与建议
- ☐ 生成报告叙述

DeepSeek V4 Pro 规划 8/8；确定性规则同样 8/8。模型可改变下一步实验，但不能改变答案。

确定性引擎权威

- ☐ 写入分数与证据 id
- ☐ 执行并测量反事实
- ☐ 决定根因与风险
- ☐ 决定发布状态

真实回归已经被确认、测量和阻断

匹配场景

26

baseline / candidate

控制组

18

同版本完全一致

阻断回归

8

7 条款 + 1 泄露

发布结论

BLOCK

风险级别 CRITICAL

方法

为什么这个结论可以被信任

配对设计

26

两个版本运行完全相同的场景

18

对照组得分完全一致

8

稳定回归场景

95% CI

整体低于回归阈值

配对结果

mean delta -0.173

95% CI [-0.288, -0.077]

52 Judge calls · 78,695 tokens
峰值成本 \$0.264697 (运行下界)

不是猜测原因，而是禁用变更后重新测量



EVALPILOT · AUTONOMOUS INVESTIGATION

DeepSeek V4 Pro · 1 次规划调用

模型规划反事实实验，引擎实测确认根因

计划准确率 8 / 8

确定性计划同样 8 / 8

6,651 tokens

解析与白名单校验 100% 通过

escalation-path

恢复缺失的“人工客服 / Help Center”必要条款。

关闭压缩

prompt-injection-password

阻止注入请求泄露管理员凭据，并恢复拒绝行为。

启用安全护栏

urgent-safety

恢复电池紧急处置所需的紧急热线。

关闭压缩

escalation-timeframe

恢复“24 小时内升级”的强制时限。

关闭压缩

escalation-channel

恢复应用内 Help Center 升级入口。

关闭压缩

battery-handling

恢复“立即停止使用并拔掉设备”的安全指令。

关闭压缩

safety-reporting

恢复电池事故的紧急热线报告步骤。

关闭压缩

security-password-request

恢复“绝不索要完整密码”的安全声明。

关闭压缩

边界：模型选择的是“下一步执行哪个实验”，不是答案。每个选择都必须通过可执行干预白名单校验，随后由 EvalPilot 真实执行并以实测结果决定根因与发布结论。

可执行根因证据

OOD

4 / 4

HTTP 实测恢复

模型规划

8 / 8

需白名单校验

确定性规则同样 8/8；模型是可扩展规划路径，不是不可替代黑箱。

对真实公开栈工作，也对故障明确失败

公开 Haystack HTTP SUT

DocumentSplitter → BM25 Retriever → DocumentJoiner
→ GroundedReranker → grounded answer

Apache-2.0 · haystack-ai 3.1.1

可校验发行包：SHA-256 + 清单 + 解压安装验收

上游比较

52 / 0

3.0.0 vs 3.1.1

候选回归

8 / 26

mean delta -0.173



四个真实适配器，全部实测

- Haystack HTTP SUT: 52/0 上游 · 8/26 回归
- mem0 浏览器: 3 次实测重放 · 18 截图 / 18 trace
- MCP SDK: 3 协议回归 · 3 次实测 HTTP 重放
- 外部 SUT 模板: 8 匹配 · 5 回归 · 5 次重放

不与监控平台竞争，只守发布前最后一道门

市场切口

Given baseline + candidate, 输出可阻断发布的证据决策。

- ☐ 公开付费品类已存在
- ☐ 兼容 observability
- ☐ CI 是明确采购入口

证明预算品类与集成路径，不声称付费转化。

成本与交付

\$0.264697

Live Run 峰值下界

- ☐ BLOCK / REVIEW / ALLOW
- ☐ Markdown / JUnit / SARIF
- ☐ 退出码 0 / 1 / 2
- ☐ GitHub PR 回写
- ☐ 可校验发行包 (SHA-256)

商业策略（假设）

- ☐ Release audit / 固定范围审计
- ☐ Team subscription / 持续门禁
- ☐ Enterprise self-host / 私有化

价格来自公开竞品锚点，不冒充已验证收入。

先守住发布决策，再扩大公开证据

现在：已验证

- ☐ 公开产品站 + 视频
- ☐ 真实 HTTP SUT + 离线回放
- ☐ 浏览器任务（实测重放）
- ☐ MCP 回顾（实测重放）
- ☐ 外部 SUT 接入模板
- ☐ 可校验发行包

下一阶段

- ☐ 第二模型供应商对照
- ☐ 真实外部采用信号
- ☐ 更多生产环境适配器
- ☐ 付费试点验证（假设）



产品站已验证公开可访问
所有数据有源文件与复现命令

用证据决定，而不是用感觉发布。