

# EvalPilot

## AI 应用回归评测 与自主发布质量官

用匹配评测、统计置信和反事实重放，把版本变化变成可验收的发布决策。

8 / 26 回归 · 52 / 0 上游比较 · 4 / 4 00D 根因

产品站: [zqian6263-design.github.io/EvalPilot](https://zqian6263-design.github.io/EvalPilot)

视频: [bilibili.com/video/BV1mPYY6sE1k](https://bilibili.com/video/BV1mPYY6sE1k)

EVALPILOT

### AI 应用发布前的 回归证据决策

#### 真实回归

不是只看总分变化，而是区分版本变更与噪声。

#### 根因定位

通过反事实重放找出导致失败的变更。

#### 可验收结论

交付可审计的发布裁决、证据与报告。

# 普通问答通过，不等于关键能力没有退化

版本更新可能更快、总分更高，却同时破坏产品必须长期守住的能力。

## 条款与流程丢失

退款、升级、电池处置等强制条款被摘要压缩掉。

## 权限与隔离失效

租户记忆串扰、缓存返回旧错误，业务边界被绕过。


## 安全护栏失效

凭证注入从拒绝泄露变成直接输出敏感信息。

需要的是：是否真实回归、由哪个变更造成、是否应立即阻断发布。



# 模型可以规划，但不能覆盖实测结论



## LLM 权限

- ☐ 提出风险假设
- ☐ 选择可执行实验
- ☐ 解释证据与建议
- ☐ 生成报告叙述

DeepSeek V4 Pro 规划 8/8；确定性规则同样 8/8。模型可改变下一步实验，但不能改变答案。

## 确定性引擎权威

- ☐ 写入分数与证据 id
- ☐ 执行并测量反事实
- ☐ 决定根因与风险
- ☐ 决定发布状态

# 真实回归已经被确认、测量和阻断

匹配场景

26

baseline / candidate

控制组

18

同版本完全一致

阻断回归

8

7 条款 + 1 泄露

发布结论

BLOCK

风险级别 CRITICAL

方法

为什么这个结论可以被信任

配对设计

26

两个版本运行完全相同的场景

18

对照组得分完全一致

8

稳定回归场景

95% CI

整体低于回归阈值

配对结果

mean delta -0.173

95% CI [-0.288, -0.077]

52 Judge calls · 78,695 tokens

峰值成本 \$0.264697 (运行下界)

# 不是猜测原因，而是禁用变更后重新测量



EVALPILOT · AUTONOMOUS INVESTIGATION

DeepSeek V4 Pro · 1 次规划调用

模型规划反事实实验，引擎实测确认根因

计划准确率 8 / 8

确定性计划同样 8 / 8

6,651 tokens

解析与白名单校验 100% 通过

|                                                                                      |                                                                                          |
|--------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| <div>escalation-path</div> <div>恢复缺失的“人工客服 / Help Center”必要条款。</div> <div>关闭压缩</div> | <div>prompt-injection-password</div> <div>阻止注入请求泄露管理员凭据，并恢复拒绝行为。</div> <div>启用安全护栏</div> |
| <div>urgent-safety</div> <div>恢复电池紧急处置所需的紧急热线。</div> <div>关闭压缩</div>                 | <div>escalation-timeframe</div> <div>恢复“24 小时内升级”的强制时限。</div> <div>关闭压缩</div>            |
| <div>escalation-channel</div> <div>恢复应用内 Help Center 升级入口。</div> <div>关闭压缩</div>     | <div>battery-handling</div> <div>恢复“立即停止使用并拔掉设备”的安全指令。</div> <div>关闭压缩</div>             |
| <div>safety-reporting</div> <div>恢复电池事故的紧急热线报告步骤。</div> <div>关闭压缩</div>              | <div>security-password-request</div> <div>恢复“绝不索要完整密码”的安全声明。</div> <div>关闭压缩</div>       |

边界：模型选择的是“下一步执行哪个实验”，不是答案。每个选择都必须通过可执行干预白名单校验，随后由 EvalPilot 真实执行并以实测结果决定根因与发布结论。

## 可执行根因证据

OOD

4 / 4

HTTP 实测恢复

模型规划

8 / 8

需白名单校验

确定性规则同样 8/8；模型是可扩展规划路径，不是不可替代黑箱。



# 不与监控平台竞争，只守发布前最后一道门

## 市场切口

Given baseline + candidate, 输出可阻断发布的证据决策。

- ☐ 公开付费品类已存在
- ☐ 兼容 observability
- ☐ CI 是明确采购入口

证明预算品类与集成路径，不声称付费转化。

## 成本与交付

\$0.264697

Live Run 峰值下界

- ☐ BLOCK / REVIEW / ALLOW
- ☐ Markdown / JUnit / SARIF
- ☐ 退出码 0 / 1 / 2
- ☐ GitHub PR 回写

## 商业策略（假设）

- ☐ Release audit / 固定范围审计
- ☐ Team subscription / 持续门禁
- ☐ Enterprise self-host / 私有化

价格来自公开竞品锚点，不冒充已验证收入。

# 先守住发布决策，再扩大公开证据

## 现在：已验证

- ☐ 公开产品站
- ☐ 真实 HTTP SUT
- ☐ 模型受约束规划
- ☐ Release Gate

## 下一阶段

- ☐ 公开未知故障回顾
- ☐ 第二模型供应商
- ☐ 真实使用信号
- ☐ 更多发布适配器



产品站已验证公开可访问  
所有数据有源文件与复现命令

用证据决定，而不是用感觉发布。